


Análisis de Prestaciones y Estimación de Costos

Arquitectura Serverless — AWS (región us-east-1)



Versión: 1.0
Fecha: Junio 2025
Región AWS: us-east-1 (N. Virginia)
Periodo: 12 meses operativos

Índice

1. Descripción de la Arquitectura	2
1.1. Inventario de Componentes	2
1.2. Flujo de Datos Principal	2
2. Análisis de Prestaciones	3
2.1. Tiempos de Respuesta por Servicio	3
2.2. Latencia Extremo a Extremo (E2E)	3
2.3. Throughput y Escalabilidad	3
2.4. Disponibilidad y SLA	4
2.5. Puntos de Atención de Rendimiento	4
3. Estimación Económica — 12 Meses (us-east-1)	4
3.1. Hipótesis de Carga	4
3.2. Desglose de Costos Mensual por Servicio	5
3.2.1. Amazon S3	5
3.2.2. Amazon Cognito	5
3.2.3. AWS WAF	6
3.2.4. Amazon API Gateway (REST)	6
3.2.5. Amazon SQS	6
3.2.6. AWS Lambda	6
3.2.7. Amazon DynamoDB (on-demand)	6
3.2.8. Amazon SNS	7
3.2.9. Amazon SES	7
3.2.10. Amazon EventBridge	7
3.2.11. Amazon CloudWatch + X-Ray	7
3.3. Resumen Mensual y Proyección Anual	8
3.4. Distribución del Gasto	8
4. Metodología de Cálculo — AWS Pricing Calculator	8
4.1. Pasos Recomendados en el Calculator	8
4.2. Rangos de Costo según Escenario	9
5. Optimizaciones de Costo Recomendadas	9
6. Conclusiones	9

1. Descripción de la Arquitectura

La arquitectura analizada es una solución *serverless* orientada a eventos, compuesta por diez servicios AWS agrupados en cinco capas funcionales. Su diseño maximiza la elasticidad, minimiza la gestión de infraestructura y desacopla los componentes de procesamiento mediante colas y eventos.

1.1. Inventario de Componentes

Componente	Servicio AWS	Rol	Protocolo/Detalle
Web UI	S3	Capa de presentación	Hosting estático
Static Storage	S3	Almacenamiento de activos	Objetos binarios
Auth Service	Cognito	Autenticación/Autorización	OAuth 2.0 / OIDC
Firewall	WAF	Seguridad perimetral	Rate limiting, reglas OWASP
API Endpoint	API Gateway	Puerta de entrada REST	HTTPS, rutas, throttling
Message Queue	SQS + DLQ	Desacoplamiento asíncrono	FIFO/Standard + DLQ
Solver Engine	Lambda (Java)	Procesamiento de lógica	Tiempo máx. 15 min
Game Repository	DynamoDB	Persistencia de datos	NoSQL, on-demand
Notification Hub	SNS	Fan-out de eventos	Pub/Sub
Email Dispatcher	SES	Notificaciones por email	SMTP / API
Scheduler	EventBridge	Disparos temporales	Rules / Scheduler
Observabilidad	CloudWatch + X-Ray	Monitoreo transversal	Métricas, trazas, logs

1.2. Flujo de Datos Principal

1. El usuario accede a la **Web UI** servida desde **S3**.
2. Las peticiones pasan por **Cognito** (autenticación) y **WAF** (filtrado de amenazas) antes de llegar al **API Gateway**.
3. El API Gateway encola los trabajos en **SQS**.
4. La **Lambda Solver Engine** (Java) consume mensajes de **SQS** y ejecuta la lógica de negocio.
5. Los resultados se persisten en **DynamoDB** y se emiten eventos de notificación a través de **SNS** → **SES**.
6. **EventBridge** lanza ejecuciones programadas que retroalimentan el flujo.
7. **CloudWatch** + **X-Ray** instrumentan todos los componentes de forma transversal.

2. Análisis de Prestaciones

2.1. Tiempos de Respuesta por Servicio

Los valores indicados corresponden a latencias de percentil P50 y P99 típicas en la región `us-east-1`, bajo carga moderada (< 500 req/s).

Cuadro 2: Latencias típicas por servicio (us-east-1)

Servicio	P50 (ms)	P99 (ms)	Observaciones
S3 (GET objeto < 1 MB)	15	80	Varía con tamaño del objeto
Cognito (token)	50	200	Incluye validación JWT
WAF	1	5	Inspección inline
API Gateway (REST)	10	50	Excluye back-end
SQS (SendMessage)	5	20	Standard queue
Lambda <i>cold start</i> (Java)	800	3 000	Primera invocación / sin SnapStart
Lambda <i>warm</i> (Java)	20	150	Ejecuciones subsiguientes
DynamoDB (read/write)	2	10	Single-digit ms garantizado
SNS (publish)	5	30	Entrega al suscriptor es asíncrona
SES (SendEmail)	100	500	Entrega al servidor de destino aparte
EventBridge (rule)	500	2 000	Tiempo hasta invocación del target
CloudWatch (PutMetricData)	20	100	Asíncrono, no bloquea el flujo

2.2. Latencia Extremo a Extremo (E2E)

El tiempo de respuesta E2E de una petición sincrónica típica es:

$$T_{E2E} = T_{S3} + T_{Cognito} + T_{WAF} + T_{APIGW} + T_{SQS} + T_{\lambda \text{ warm}} + T_{DDB} \quad (1)$$

$$T_{E2E}^{P50} \approx 15 + 50 + 1 + 10 + 5 + 20 + 2 = \mathbf{103 \text{ ms}}$$

$$T_{E2E}^{P99} \approx 80 + 200 + 5 + 50 + 20 + 150 + 10 = \mathbf{515 \text{ ms}}$$

Nota: El *cold start* de Lambda Java puede elevar el P99 hasta $\sim 3,5$ s en el primer arranque. Se recomienda activar **Lambda SnapStart** para runtimes Java 11/21, reduciendo el cold start a < 100 ms.

2.3. Throughput y Escalabilidad

Cuadro 3: Límites de escalabilidad por servicio (cuotas blandas por defecto)

Servicio	Límite por defecto	Ampliable
API Gateway (req/s)	10 000	Sí, vía AWS Support
Lambda (conurrencia)	1 000	Sí, hasta cientos de miles
SQS (msg/s por cola)	Ilimitado	—
DynamoDB	Ilimitado (on-demand)	—
SES (emails/s)	14	Sí, tras salida de <i>sandbox</i>
Cognito (req/s)	1 200	Sí

2.4. Disponibilidad y SLA

Cuadro 4: SLAs de disponibilidad declarados por AWS

Servicio	SLA	Downtime máx./año
S3	99.9 %	8,7 h
API Gateway	99.95 %	4,4 h
Lambda	99.95 %	4,4 h
DynamoDB	99.999 %	5,3 min
SQS	99.9 %	8,7 h
Cognito	99.9 %	8,7 h
SES	99.9 %	8,7 h
SNS	99.9 %	8,7 h

La disponibilidad compuesta del flujo crítico (todos los servicios en serie) es:

$$A_{\text{sistema}} = \prod_i A_i = 0,999 \times 0,9995 \times 0,9995 \times \dots \approx \mathbf{99,7\%} \quad (2)$$

2.5. Puntos de Atención de Rendimiento

1. **Cold start Java:** Principal cuello de botella de latencia. Mitigación: Lambda SnapStart, Provisioned Concurrency, o migración a runtime GraalVM nativo.
2. **DLQ (Dead Letter Queue):** Garantiza que mensajes no procesados no se pierdan. Se deben configurar alarmas CloudWatch sobre la métrica `NumberOfMessagesSent` en la DLQ.
3. **Throttling de Cognito:** A más de 1 200 req/s es necesario caché de tokens en el cliente o incrementar la cuota.
4. **SES en Sandbox:** Limitado a 14 emails/s y destinatarios verificados. Solicitar la salida del sandbox para producción.
5. **Consistencia eventual DynamoDB:** Las lecturas por defecto son *eventually consistent*. Usar lecturas fuertemente consistentes donde el negocio lo requiera (doble coste de RCU).

3. Estimación Económica — 12 Meses (us-east-1)

3.1. Hipótesis de Carga

Las estimaciones se basan en los siguientes supuestos de uso **moderado-producción**:

Cuadro 5: Hipótesis de dimensionamiento

Parámetro	Valor/mes	Justificación
Peticiones API	10 000 000	~333 K/día
Invocaciones Lambda	10 000 000	1:1 con API
Duración media Lambda	500 ms	Solver Java moderado
Memoria Lambda	512 MB	—
Mensajes SQS	20 000 000	Request + respuesta
Lecturas DynamoDB (RCU)	50 000 000	5 reads / petición
Escrituras DynamoDB (WCU)	10 000 000	1 write / petición
Almacenamiento DynamoDB	10 GB	—
Datos en S3	50 GB	UI + assets
Solicitudes S3 PUT/GET	5 000 000	—
Usuarios Cognito activos	10 000	MAU
Emails enviados (SES)	200 000	2 % de peticiones
Notificaciones SNS	500 000	—
Reglas EventBridge	10	Ejecuciones programadas
Métricas CloudWatch	50	Métricas personalizadas
Logs CloudWatch	20 GB	—
Trazas X-Ray	10 000 000	1 traza / petición
WAF (web ACL + reglas)	1 ACL, 3 reglas	Básico

3.2. Desglose de Costos Mensual por Servicio

3.2.1. Amazon S3

Concepto	Cantidad	Precio unitario	Costo/mes
Almacenamiento Standard	50 GB	\$ 0.023/GB	\$ 1.15
PUT/COPY/POST/LIST (por 1K)	1 000 K	\$ 0.005/1K	\$ 5.00
GET/SELECT (por 1K)	4 000 K	\$ 0.0004/1K	\$ 1.60
Data transfer OUT (10 GB)	10 GB	\$ 0.09/GB	\$ 0.90
Subtotal mensual S3			\$ 8.65

3.2.2. Amazon Cognito

Concepto	Cantidad	Precio unitario	Costo/mes
MAU (primeros 50 K gratuitos)	10 000	\$ 0.00	\$ 0.00
Subtotal mensual Cognito			\$ 0.00

Los primeros 50.000 MAU por mes son gratuitos en el nivel esencial.

3.2.3. AWS WAF

Concepto	Cantidad	Precio unitario	Costo/mes
Web ACL	1	\$ 5.00/ACL	\$ 5.00
Reglas	3	\$ 1.00/regla	\$ 3.00
Peticiones (por 1M)	10	\$ 0.60/1M	\$ 6.00
Subtotal mensual WAF			\$ 14.00

3.2.4. Amazon API Gateway (REST)

Concepto	Cantidad	Precio unitario	Costo/mes
Llamadas API (primeros 333M)	10M	\$ 3.50/M	\$ 35.00
Caché (0.5 GB, opcional)	—	—	\$ 0.00
Subtotal mensual API Gateway			\$ 35.00

3.2.5. Amazon SQS

Concepto	Cantidad	Precio unitario	Costo/mes
Solicitudes Standard (primero 1M gratis)	20M	\$ 0.40/M	\$ 7.60
Subtotal mensual SQS			\$ 7.60

3.2.6. AWS Lambda

Concepto	Cantidad	Precio unitario	Costo/mes
Invocaciones (primero 1M gratis)	10M	\$ 0.20/M	\$ 1.80
GB-segundo (512 MB × 0,5 s × 10M)	2.500.000	\$ 0.0000166667/GB-s	\$ 41.67
Subtotal mensual Lambda			\$ 43.47

Los primeros 400 000 GB-segundos/mes son gratuitos y ya se han descontado.

3.2.7. Amazon DynamoDB (on-demand)

Concepto	Cantidad	Precio unitario	Costo/mes
Write Request Units (WRU)	10M	\$ 1.25/M	\$ 12.50
Read Request Units (RRU)	50M	\$ 0.25/M	\$ 12.50
Almacenamiento	10 GB	\$ 0.25/GB	\$ 2.50
Subtotal mensual DynamoDB			\$ 27.50

3.2.8. Amazon SNS

Concepto	Cantidad	Precio unitario	Costo/mes
Publicaciones (primeras 1M gratis)	500K	\$ 0.00	\$ 0.00
Entregas HTTP/Lambda	500K	\$ 0.06/100K	\$ 0.30
Subtotal mensual SNS			\$ 0.30

3.2.9. Amazon SES

Concepto	Cantidad	Precio unitario	Costo/mes
Emails enviados	200K	\$ 0.10/1K	\$ 20.00
Adjuntos (asumido nulo)	—	—	\$ 0.00
Subtotal mensual SES			\$ 20.00

3.2.10. Amazon EventBridge

Concepto	Cantidad	Precio unitario	Costo/mes
Eventos (primero 1M gratis/custom bus)	<1M	\$ 0.00	\$ 0.00
Scheduler invocaciones	500K	\$ 1.00/M	\$ 0.50
Subtotal mensual EventBridge			\$ 0.50

3.2.11. Amazon CloudWatch + X-Ray

Concepto	Cantidad	Precio unitario	Costo/mes
Métricas personalizadas	50	\$ 0.30/métrica	\$ 15.00
Logs ingesta	20 GB	\$ 0.50/GB	\$ 10.00
Logs almacenamiento (30 días)	20 GB	\$ 0.03/GB	\$ 0.60
X-Ray trazas grabadas	10M	\$ 5.00/M (sobre 100K gratis)	\$ 49.50
Dashboards (1 dashboard)	1	\$ 3.00/dashboard	\$ 3.00
Subtotal mensual Observabilidad			\$ 78.10

3.3. Resumen Mensual y Proyección Anual

Cuadro 6: Costo total mensual por servicio — hipótesis moderada

Servicio	Costo/mes (USD)	Costo/año (USD)
Amazon S3 (2 buckets)	8.65	103.80
Amazon Cognito	0.00	0.00
AWS WAF	14.00	168.00
Amazon API Gateway	35.00	420.00
Amazon SQS (+ DLQ)	7.60	91.20
AWS Lambda (Java)	43.47	521.64
Amazon DynamoDB	27.50	330.00
Amazon SNS	0.30	3.60
Amazon SES	20.00	240.00
Amazon EventBridge	0.50	6.00
CloudWatch + X-Ray	78.10	937.20
TOTAL	235.12	2.821.44

3.4. Distribución del Gasto

La siguiente tabla muestra el peso relativo de cada servicio sobre el costo total mensual:

Servicio	% del total mensual	Relevancia
CloudWatch + X-Ray	33.2 %	Alto
API Gateway	14.9 %	Medio-alto
Lambda	18.5 %	Medio-alto
DynamoDB	11.7 %	Medio
SES	8.5 %	Bajo-medio
WAF	6.0 %	Bajo
S3	3.7 %	Bajo
Resto	3.5 %	Bajo

4. Metodología de Cálculo — AWS Pricing Calculator

Los precios empleados corresponden a la tarifa pública de **AWS Pricing Calculator** (<https://calculator.aws/pricing/2/home>) para la región **us-east-1** (N. Virginia), consultados en junio de 2025. Los precios no incluyen impuestos.

4.1. Pasos Recomendados en el Calculator

1. Acceder a <https://calculator.aws/pricing/2/home> y crear una **nueva estimación**.
2. Seleccionar región **US East (N. Virginia)** en todos los servicios.
3. Añadir cada servicio de la tabla de inventario usando los valores de la Sección 3.1.

4. Para **Lambda**: indicar invocaciones, duración media y memoria asignada.
5. Para **DynamoDB**: seleccionar modo *On-Demand* e introducir RRU/WRU y almacenamiento.
6. Para **API Gateway**: elegir tipo REST y número de llamadas.
7. Para **CloudWatch**: sumar métricas personalizadas, volumen de logs y trazas X-Ray.
8. Exportar el resumen en PDF o CSV para documentación oficial.

4.2. Rangos de Costo según Escenario

Cuadro 7: Estimación en tres escenarios de uso

Escenario	Req/mes	Costo/mes	Costo anual
Bajo (piloto / dev)	500K	~ \$ 45	~ \$ 540
Moderado (producción)	10M	~ \$ 235	~ \$ 2 821
Alto (escala)	100M	~ \$ 1 850	~ \$ 22 200

5. Optimizaciones de Costo Recomendadas

1. **Reducir X-Ray sampling**: Configurar una tasa de muestreo del 5 % en lugar de 100 % reduce el costo de X-Ray de \$ 49.50 a ~ \$ 2.50/mes.
2. **API Gateway HTTP vs REST**: Migrar a *HTTP API* reduce el precio por millón de llamadas de \$ 3.50 a \$ 1.00, ahorrando ~ \$ 25/mes.
3. **Lambda SnapStart (Java)**: Elimina el cold start sin coste adicional para Java 11/21.
4. **DynamoDB Reserved Capacity**: A partir de carga predecible, contratar capacidad reservada reduce el costo hasta un 77 %.
5. **CloudWatch Log retention**: Ajustar retención a 7 días en entornos de producción reduce costos de almacenamiento de logs.
6. **S3 Intelligent-Tiering**: Para el bucket Static Storage, activar I-T mueve automáticamente objetos no accedidos a capas más baratas.
7. **Savings Plans Compute**: Si Lambda supera los \$ 100/mes consistentemente, los Compute Savings Plans ofrecen hasta un 17 % de descuento.

6. Conclusiones

1. La arquitectura es **sólida y bien diseñada**: el desacoplamiento mediante SQS, la autenticación centralizada en Cognito, el WAF perimetral y la observabilidad transversal son buenas prácticas de arquitectura en la nube.

2. El **costo operativo anual estimado** para un escenario de producción moderado asciende a **\$ 2 821** en la región **us-east-1**, lo cual es competitivo para una solución sin gestión de servidores.
3. El **mayor coste unitario** recae en CloudWatch/X-Ray (33 %) y Lambda (18 %). Reducir el sampling de X-Ray y optimizar la duración de las funciones Lambda son las palancas de optimización más eficaces.
4. La **latencia E2E** esperada es de ~ 100 ms en P50 y ~ 500 ms en P99 (flujo sincrónico), siendo el *cold start* de Lambda Java el principal riesgo de latencia puntual.
5. Para validar y obtener una estimación oficial actualizada, se recomienda introducir los parámetros de la Sección 3.1 directamente en el **AWS Pricing Calculator** y exportar el informe resultante.

Documento generado a partir del archivo `architecture-simplified.drawio`. Los precios son orientativos y pueden variar. Para contratación formal, consultar la tarifa oficial en <https://aws.amazon.com/pricing/>.